

SEO-Keyword → ContentBrief Pipeline

für zvoove

500 Keywords · 13 thematische Cluster

Bewerbung als Revenue AI Architect

Agenda

— hier später Outline einfügen —

1. Aufgabe
2. Anforderungen & mein Ansatz
3. Ergebnis
4. Architektur
5. Cluster-Schritt im Detail
6. Briefs & Reporting
7. Drei Empfehlungen für zvoove
8. Limits & nächste Schritte

Was ist die Aufgabe?

Automatisiere den Prozess:

Quelle → Keywords → Cluster → Content Brief → Reporting

Beispiel:

zvoove.de/wissen/blog → 500 Keywords → 13 Cluster → 13 Briefs → Dashboard

Warum?

Im Bereich Zeitarbeit und Personaldienstleistung **organischen Traffic gewinnen, der echte Kaufinteressenten bringt.**

Leitkriterien

1 · Integration & Continuous Delivery

Quelle per API oder CSV · Reporting als JSON/CSV · code-seitig erweiterbar Richtung Google Sheets, Airtable, Notion, CMS.

2 · Provider-unabhängig — keine Lock-in-Abhängigkeit

LLM-Call über verschiedene Anbieter: Anthropic heute, OpenAI oder lokales Modell morgen — ohne Pipeline-Umbau.

3 · Technisch maintainable und übergebbar

42 Tests, versioniert, validiert (Silhouette + ARI), reproduzierbar.

4 · Modular und testable

Sechs entkoppelte Schritte. Jeder einzeln testbar, einzeln austauschbar.

Ergebnis in zwei Zahlen

500

Keywords

13

Cluster

240k

Suchen / Monat


Validiert mit Silhouette 0,65 und ARI 0,81 gegen ein zweites Verfahren.

Drei interessante Cluster

Cluster	SV/Monat	Kommerziell	Hebel
HR- & Dokumentenverwaltungssoftware	45.000	89 %	Bottom-of-Funnel
Zvoove Plattform & Preise	23.000	97 %	Brand Defense
Digitalisierung Personaldienstleistung	24.000	35 %	Top-of-Funnel

Vollständige Tabelle aller 13 Cluster im Dashboard.

Architektur: 6 entkoppelte Schritte



Warum entkoppelt?

- Embeddings einmal rechnen
- Cluster-Tuning ohne Neukosten
- Briefs nicht versehentlich neu erzeugen
- Jeder Schritt einzeln ersetzbar

Discover: ehrlicher Stand

Aktuell: Stub. Liest ein kuratiertes Keyword-Set aus CSV.

Geplant: Live-Scraping vom Blog plus Claude-basierte Keyword-Expansion.

Warum nicht jetzt?

Web-Scraping ist konzeptionell der schwierigste Schritt: Anti-Bot, JavaScript-Rendering, Pagination.
Lieber **vier Schritte richtig fertig** als sechs halb fertig.

Trade-off transparent in den Architecture Decision Records dokumentiert.

Cluster-Schritt: was ist ein Embedding?

Ein **Embedding** ist eine Zahlenfolge, die die Bedeutung eines Texts beschreibt.

Beispiel:

Lohnabrechnung Software $\approx$ Payroll Tool

Andere Wörter, gleiche Bedeutung, **ähnliche Zahlen**.

Modell: `paraphrase-multilingual-MiniLM-L12-v2` · mehrsprachig · 120 MB · läuft ohne GPU

Cluster-Schritt: warum HDBSCAN?

k-means

- Clusteranzahl muss vorgegeben werden
- Kein Outlier-Konzept
- Setzt sphärische Cluster voraus

HDBSCAN ✓

- Findet die Anzahl selbst
- Markiert Ausreißer als Rauschen
- Variable Cluster-Dichte

Beispiel: `fachkräftemangel deutschland` — gehört semantisch zu nichts. HDBSCAN sagt das. k-means würde es zwanghaft zuordnen.

Woran erkennt man gutes Clustering?

Kein Goldstandard ohne Labels —
deshalb validieren.

Nicht eine einzelne Kennzahl entscheidet — sondern ein konsistentes Gesamtbild.

Trennschärfe

Innerhalb ähnlich, zwischen Clustern
verschieden

1

Silhouette = 0,65

solide Trennung
(> 0,5 gilt als gut)

Stabilität

Unabhängiges Verfahren findet
ähnliche Struktur

2

ARI = 0,81

hohe Übereinstimmung
mit Ward(k=10)

Plausibilität

Parameter systematisch und
Segmente interpretierbar

3

Grid Search

reproduzierbar,
nichts geraten

Fazit Die Cluster sind nicht zufällig, sondern belastbar und interpretierbar.

Lesart: gutes Clustering = getrennt + stabil + reproduzierbar + fachlich sinnvoll
Damit ist die Segmentierung stark genug für die nächste Ebene: Profilierung und fachliche Interpretation der Cluster.

Briefs mit Claude + Prompt Caching

Pro Cluster ein Markdown-Brief mit:

Hauptkeyword, Suchintention, Zielgruppe, Outline (H1–H3), 3 Benchmark-URLs, CTA.

Prompt Caching: System-Prompt wird einmal gecached, 13× wiederverwendet

→ rund **90 % Token-Ersparnis**, < 1 USD pro Lauf.

Robust: Retry mit Backoff. Wenn ein Brief fehlschlägt, läuft die Pipeline weiter. Status-Bericht am Ende.

Reporting & Export

Report: eine HTML-Datei mit KPIs, Cluster-Tabelle, Charts, Karten-Link.
Bewusst kein Frontend-Framework. Verschickbar per Mail oder Slack.

Export: drei JSON-Dateien

Datei	Inhalt
<code>clusters.json</code>	eine Zeile pro Cluster
<code>keywords.json</code>	eine Zeile pro Keyword
<code>report.json</code>	alles zusammen

Optional: direkter Sync nach Airtable oder Google Sheets, per Schalter.

Empfehlung 1: HR-Software

45.000 Suchen / Monat

89 % kommerziell · KD ø 53 · 45 Keywords

Top-Keywords:

dokumentenmanagement software · bewerbermanagement software ·
mitarbeiterverwaltung software · hr software kmu

Was tun: Pillar-Pages zu Software-Kategorien, jeweils mit zvoove-Modul als Lösung.

Hypothese: 5 % CTR × 2 % MQL-Rate ≈ **45 MQLs / Monat.**

Empfehlung 2: zvoove-Marken-Keywords

23.000 Suchen / Monat

97 % kommerziell · KD ø 52 · 34 Keywords

Auffällig: KD 52 für Brand-Begriffe ist **ungewöhnlich hoch**.

→ Vergleichsseiten und Bewertungsportale belegen die SERP.

Was tun: zvoove-Erfahrungen-Hub unter `/produkte/`, der positive Bewertungen aggregiert.

Defense und Offense in einem.

Empfehlung 3: Digitalisierung

24.000 Suchen / Monat

35 % kommerziell · KD ø 36 · 37 Keywords · **Top-of-Funnel**

Top-Keywords:

digitalisierung zeitarbeit · künstliche intelligenz personaldienstleistung ·
digitale zeiterfassung

Was tun: Hub </wissen/digitalisierung-personaldienstleistung/>, der Awareness-Traffic in die kommerziellen Cluster überführt.

Wirkung: Pipeline-Influence über 6–12 Monate, nicht direkte Conversion.

Limits & nächste Schritte

Was fehlt

- Discover ist Stub
- Keine Datenbank, nur Dateien
- Keine GSC-Anbindung

Was als Nächstes

1. Discover live machen
2. Search Console anbinden
3. SQLite-Persistenz
4. CMS-Integration (Sanity)

Bei einer zweiten Iteration: Discover zuerst bauen, nicht zuletzt.

Was diese Pipeline zeigen soll

Architektur-Denken statt Skript-Denken

→ jeder Schritt einzeln ersetzbar

Pragmatismus statt Polish

→ Heuristik klar markiert, Live-Daten optional

Revenue-Lens auf alles

→ jede Empfehlung mit MQL-Hypothese

Danke.

Repo: `github.com/t1nak/seo-pipeline`

Live-Dashboard: `t1nak.github.io/seo-pipeline`

Fragen?