

SEO-Keyword → ContentBrief Pipeline

für zvoove

Bewerbung als Revenue AI Architect

Agenda

1. Aufgabe & Leitkriterien
2. Pipeline: Automatisierung & Architektur
3. Clustering-Methodik (Embedding, HDBSCAN, Validierung)
4. Briefs, Reporting & Kosten
5. Ergebnisse
6. Stärken, Schwächen, Future Work
7. Extra: Drei Cluster-Empfehlungen

Was ist die Aufgabe?

Automatisiere den Prozess:

Quelle → Keywords → Cluster → Content Brief → Reporting

Beispiel:

`zvoove.de/wissen/blog` → 500 Keywords → 13 Cluster → 13 Briefs → Dashboard

Warum?

Im Bereich Zeitarbeit und Personaldienstleistung **organischen Traffic gewinnen, der echte Kaufinteressenten bringt.**

Lösungsansatz:

Python-Pipeline orchestriert mit GitHub Actions. HDBSCAN für Clustering, LLM-Calls für Labels, Briefs und Keyword-Generierung.

Leitkriterien

1 · Integration in verschiedene Systeme

- Dateneingang per API oder CSV; Ergebnisse in einem Dashboard, JSON oder CSV
- Mögliche erweiterte Darstellung in Google Sheets, Notion etc.

Leitkriterien

1 · Integration in verschiedene Systeme

- Dateneingang per API oder CSV; Ergebnisse in einem Dashboard, JSON oder CSV
- Mögliche erweiterte Darstellung in Google Sheets, Notion etc.

2 · Provider-unabhängig, kein Vendor Lock-in

- LLM-Call über verschiedene Anbieter möglich (Anthropic, OpenAI, lokales Modell)

Leitkriterien

1 · Integration in verschiedene Systeme

- Dateneingang per API oder CSV; Ergebnisse in einem Dashboard, JSON oder CSV
- Mögliche erweiterte Darstellung in Google Sheets, Notion etc.

2 · Provider-unabhängig, kein Vendor Lock-in

- LLM-Call über verschiedene Anbieter möglich (Anthropic, OpenAI, lokales Modell)

3 · Transparente und steuerbare Nutzbarkeit

- Technische Qualität durch Tests und Validierungsmetriken
- Nachvollziehbar; gute Dokumentation

Leitkriterien

1 · Integration in verschiedene Systeme

- Dateneingang per API oder CSV; Ergebnisse in einem Dashboard, JSON oder CSV
- Mögliche erweiterte Darstellung in Google Sheets, Notion etc.

2 · Provider-unabhängig, kein Vendor Lock-in

- LLM-Call über verschiedene Anbieter möglich (Anthropic, OpenAI, lokales Modell)

3 · Transparente und steuerbare Nutzbarkeit


- Technische Qualität durch Tests und Validierungsmetriken
- Nachvollziehbar; gute Dokumentation

4 · Modularer, wartbarer Aufbau

- Reproduzierbare Pipeline
- Sechs getrennte Prozessschritte (einzeln testbar und austauschbar)

Automatisierung

GitHub Actions · Auslöser per Cron-Schedule oder manueller Trigger



Infrastruktur · unsichtbar aber überall

Secrets

Run-Logs

Retry-Logik

Git-Versionierung

Architektur: 6 Schritte



Discover sagt, welche Keywords.

Enrich sagt, was sie wert sind.

Cluster gruppiert und aggregiert sie.

Brief erstellt für jeden Cluster (außer Noise) einen Brief.

Report bündelt alles in ein Dashboard.

Export liefert JSON für externe Systeme (Airtable, Notion, Sheets).

Ergebnisse

500 Keywords, 13 Cluster

[Dashboard](#) · [Cluster-Map](#) · [Letzter Lauf](#)

Das HDBSCAN-Clustering ist methodisch abgesichert:

- gute interne Clusterqualität und starke Übereinstimmung mit Vergleichsverfahren, das die Stabilität der Ergebnisse unterstützt (Ward-Clustering)
-> gefundenen Cluster sind robust, nicht zufällig oder modellabhängig

Cluster-Schritt: was ist ein Embedding?

Ein **Embedding** ist eine Zahlenfolge, die die semantische Bedeutung eines Texts mathematisch geometrisch beschreibt.

```
Input          → Embedding-Modell      → 384-dim Vektor pro Keyword
"hr software"  → MiniLM                → [0.12, -0.34, 0.81, ...]
                                     |
                                     ▼
                                UMAP (384D → 5D)
                                     |
                                     ▼
                                HDBSCAN → Cluster-Label
```

Modell: `paraphrase-multilingual-MiniLM-L12-v2` · mehrsprachig · 120 MB · läuft ohne GPU

Woran erkennt man gutes Clustering?

Trennschärfe

Innerhalb ähnlich, zwischen Clustern verschieden

1

Silhouette = 0,65

solide Trennung
(> 0,5 gilt als gut)

Stabilität

Unabhängiges Verfahren findet ähnliche Struktur

2

ARI = 0,94

hohe Übereinstimmung
mit Ward(k=13)

Plausibilität

Parameter systematisch und Segmente interpretierbar

3

Grid Search

reproduzierbar,
nichts geraten

Fazit Die Cluster sind nicht zufällig, sondern belastbar und interpretierbar.

Briefs mit Claude + Prompt Caching

Pro Cluster ein Markdown-Brief mit:

Hauptkeyword, Suchintention, Zielgruppe, Outline (H1–H3), 3 Benchmark-URLs, CTA.

Prompt Caching: System-Prompt wird einmal gecached, 13× wiederverwendet
→ rund **90 % Token-Ersparnis**, < 1 USD pro Lauf.

Fehlertolerante Pipeline: Bei temporären Fehlern wird die Generierung automatisch erneut versucht. Schlägt ein einzelner Brief fehl, läuft der Prozess weiter und gibt am Ende einen Statusbericht aus.

Reporting & Export

Report

HTML Dashboard

KPIs, Cluster-Tabelle, Charts, Karten-Link

Kein Framework

Mail-ready

Export

JSON-Dateien

`clusters.json` · `keywords.json` · `report.json`

Pro Cluster

Pro Keyword

Sync

Optional

Direkter Push zu externen Plattformen

Airtable

Sheets

Notion

Was kostet ein Pipeline-Run?

Lokal / GitHub Actions VM (0 USD)

Embeddings (MiniLM), UMAP, HDBSCAN

API-Calls ($\approx 0,21$ USD)

Cluster-Labels (Haiku) + 13 Briefs (Sonnet mit Caching)

Optional ($\approx 0,75$ USD)

DataForSEO Search Volume Enrichment

≈ 1 USD

pro vollem Lauf

Stärken, Schwächen, Future Work

Stärken

- Automatisierter, nachvollziehbarer Workflow mit hoher Wartbarkeit und Anpassbarkeit
- Systematischer Parameter-Sweep zur Bewertung unterschiedlicher Konfigurationen
- Fundierter Clustering-Vergleich zwischen HDBSCAN und Ward

Schwächen

- Discover basiert auf LLM-generierten CSV-Daten; belastbarer wäre Scraping oder SEMrush-API
- Branch-Struktur benötigt Bereinigung (Entwicklung, Experimente, Produktion trennen)

Future Work

- Discover belastbar machen
- Datenbank und Run-Historie: Artefakte versioniert speichern
- Pydantic für Validierung, besseres Typing

Danke.

Repo: `github.com/t1nak/seo-pipeline`

Live-Dashboard: `t1nak.github.io/seo-pipeline`

Fragen?

Extra.

SEO: Content discussion

Drei interessante Cluster

**HR- & Dokumenten-
verwaltungssoftware**

45.000

Suchen / Monat

89 % kommerziell · KD ø 53

Bottom-of-Funnel

zvoove Plattform & Preise

23.000

Suchen / Monat

97 % kommerziell · KD ø 52

Brand Defense

**Digitalisierung Personal-
dienstleistung**

24.000

Suchen / Monat

35 % kommerziell · KD ø 36

Top-of-Funnel

Bottom-of-Funnel · kaufbereit, vergleicht
Lösungen

Brand Defense · sucht nach uns, will
Beweise

Top-of-Funnel · recherchiert,
noch früh

Vollständige Tabelle aller 13 Cluster im Dashboard.

Empfehlung 1: HR-Software

45.000

Suchen / Monat

89 % kommerziell

KD ø 53

45 Keywords

Top-Keywords

`dokumentenmanagement software` · `bewerbermanagement software` · `mitarbeiterverwaltung software` · `hr software kmu`

Was tun: Pillar-Pages zu Software-Kategorien, jeweils mit zvoove-Modul als Lösung.

Hypothese: 5 % CTR × 2 % MQL-Rate ≈ **45 MQLs / Monat**

Empfehlung 2: zvoove-Marken-Keywords

23.000 Suchen / Monat

97 % kommerziell · KD ø 52 · 34 Keywords

Auffällig: KD 52 für Brand-Begriffe ist **ungewöhnlich hoch**.

→ Vergleichsseiten und Bewertungsportale belegen die SERP.

Was tun: zvoove-Erfahrungen-Hub unter `/produkte/`, der positive Bewertungen aggregiert.

Defense und Offense in einem.

Empfehlung 3: Digitalisierung

24.000 Suchen / Monat

35 % kommerziell · KD ø 36 · 37 Keywords · **Top-of-Funnel**

Top-Keywords:

digitalisierung zeitarbeit · künstliche intelligenz personaldienstleistung ·
digitale zeiterfassung

Was tun: Hub </wissen/digitalisierung-personaldienstleistung/>, der Awareness-Traffic in die kommerziellen Cluster überführt.

Wirkung: Pipeline-Influence über 6–12 Monate, nicht direkte Conversion.

Cluster-Schritt: warum HDBSCAN?

k-means

- Clusteranzahl muss vorgegeben werden
- Kein Outlier-Konzept
- Setzt sphärische Cluster voraus

HDBSCAN ✓

- Findet die Anzahl selbst
- Markiert Ausreißer als Rauschen
- Variable Cluster-Dichte

Beispiel: `fachkräftemangel deutschland` — gehört semantisch zu nichts. HDBSCAN sagt das. k-means würde es zwanghaft zuordnen.